

# Atividade prática 5

## Álgebra Linear Numérica

Pedro Henrique Coterli

13 de junho de 2024

### Exercício 1

Façamos nossa função de decomposição  $QR$  com Gram-Schmidt.

```
// Função de decomposição QR de Gram-Schmidt
function [Q, R] = qr_GS(A)
    // Pegando as dimensões da A
    [m, n] = size(A)
    // Inicializando as matrizes Q e R
    Q = zeros(m, n)
    R = zeros(n, n)

    // Para cada coluna...
    for j = 1:n
        // Inicializa o vetor v como a coluna de A
        v = A(:, j)
        // Se não for a primeira coluna...
        if j > 1 then
            // Calcula o termo de projeção de v
            R(1:(j-1), j) = (Q(:, 1:(j-1)))' * A(:, j)
            // Calcula a ortogonalização de v
            v = v - Q(:, 1:(j-1)) * R(1:(j-1), j)
        end
        // Salva o termo da diagonal de R como a norma de v
        R(j, j) = norm(v)
        // Salva a coluna de Q como o vetor v normalizado
        Q(:, j) = v / R(j, j)
    end
endfunction
```

Vamos testá-la com algumas matrizes retangulares, calculando os erros do produto  $QR$  com a matriz  $A$  e da ortogonalidade da matriz  $Q$ .

```
// Gerando uma matriz
A1 = round(20*rand(3, 2) - 10)
// Calculando a decomposição QR
```

```
[Q1, R1] = qr_GS(A1);
disp("norm(Q*R - A)", norm(Q1*R1 - A1))
disp("norm(Q^T*Q - I)", norm(Q1'*Q1 - eye(2, 2)))
```

```
A1 =
    2.    9.
   -2.    7.
    4.   -3.
```

```
"norm(Q*R - A)"
```

```
1.776D-15
```

```
"norm(Q^T*Q - I)"
```

```
2.292D-16
```

```
A2 = round(20*rand(4, 3) - 10)
[Q2, R2] = qr_GS(A2);
disp("norm(Q*R - A)", norm(Q2*R2 - A2))
disp("norm(Q^T*Q - I)", norm(Q2'*Q2 - eye(3, 3)))
```

```
A2 =
    8.    9.    5.
   -8.   10.    1.
    1.    2.    5.
    1.   10.   -9.
```

```
"norm(Q*R - A)"
```

```
1.891D-15
```

```
"norm(Q^T*Q - I)"
```

```
2.562D-16
```

```
A3 = round(20*rand(5, 5) - 10)
[Q3, R3] = qr_GS(A3);
disp("norm(Q*R - A)", norm(Q3*R3 - A3))
disp("norm(Q^T*Q - I)", norm(Q3'*Q3 - eye(5, 5)))
```

```
A3 =
   -2.    8.    6.   -5.    4.
   -8.    5.    4.    4.   -4.
   -5.    1.   -8.    9.   -7.
   -3.   -2.   -5.    0.    4.
   -7.    8.    5.   -5.   -1.
```

```
"norm(Q*R - A)"
```

```
8.882D-16
```

```
"norm(Q^T*Q - I)"
```

```
6.279D-16
```

Parece que nossa função está funcionando bem.

## Exercício 2

Agora, façamos a função da decomposição  $QR$  com Gram-Schmidt modificado. Infelizmente, para essa versão, não é possível calcular o loop interno matricialmente devido à atualização do vetor  $v$ , sendo necessário um loop `for`.

```
// Função de decomposição QR de Gram-Schmidt
function [Q, R] = qr_GSM(A)
    // Pegando as dimensões da A
    [m, n] = size(A)
    // Inicializando as matrizes Q e R
    Q = zeros(m, n)
    R = zeros(n, n)

    // Para cada coluna...
    for j = 1:n
        // Inicializa o vetor v como a coluna de A
        v = A(:, j)
        // Para cada linha...
        for i = 1:(j-1)
            // Calcula o fator de projeção do v sobre qi
            R(i, j) = Q(:, i)' * v
            // Ortogonaliza em relação ao qi
            v = v - R(i, j) * Q(:, i)
        end
        // Salva o termo da diagonal de R como a norma de v
        R(j, j) = norm(v)
        // Salva a coluna de Q como o vetor v normalizado
        Q(:, j) = v / R(j, j)
    end
endfunction
```

Vamos agora testá-la com as mesmas matrizes usadas no exercício anterior, comparando a precisão dos dois algoritmos.

```
// Calculando a decomposição QR pelo GS modificado
[QM1, RM1] = qr_GSM(A1);
```

```

disp("=====Gram-Schmidt =====")
disp("norm(Q*R - A)", norm(Q1*R1 - A1))
disp("norm(Q^T*Q - I)", norm(Q1'*Q1 - eye(2, 2)))
disp("=====Gram-Schmidt modificado =====")
disp("norm(Q*R - A)", norm(QM1*RM1 - A1))
disp("norm(Q^T*Q - I)", norm(QM1'*QM1 - eye(2, 2)))

```

"=====**Gram-Schmidt** ====="

"norm(Q\*R - A)"

1.776D-15

"norm(Q^T\*Q - I)"

2.292D-16

"=====**Gram-Schmidt modificado** ====="

"norm(Q\*R - A)"

1.776D-15

"norm(Q^T\*Q - I)"

2.292D-16

```
[QM2, RM2] = qr_GSM(A2);
```

```

disp("=====Gram-Schmidt =====")
disp("norm(Q*R - A)", norm(Q2*R2 - A2))
disp("norm(Q^T*Q - I)", norm(Q2'*Q2 - eye(3, 3)))
disp("=====Gram-Schmidt modificado =====")
disp("norm(Q*R - A)", norm(QM2*RM2 - A2))
disp("norm(Q^T*Q - I)", norm(QM2'*QM2 - eye(3, 3)))

```

"=====**Gram-Schmidt** ====="

"norm(Q\*R - A)"

1.891D-15

"norm(Q^T\*Q - I)"

2.562D-16

"=====**Gram-Schmidt modificado** ====="

```
"norm(Q*R - A)"
```

```
1.891D-15
```

```
"norm(Q^T*Q - I)"
```

```
2.562D-16
```

```
[QM3, RM3] = qr_GSM(A3);
```

```
disp("=====  
disp("norm(Q*R - A)", norm(Q3*R3 - A3))  
disp("norm(Q^T*Q - I)", norm(Q3'*Q3 - eye(5, 5)))  
disp("=====  
disp("norm(Q*R - A)", norm(QM3*RM3 - A3))  
disp("norm(Q^T*Q - I)", norm(QM3'*QM3 - eye(5, 5)))
```

```
"=====  
Gram-Schmidt ====="
```

```
"norm(Q*R - A)"
```

```
8.882D-16
```

```
"norm(Q^T*Q - I)"
```

```
6.279D-16
```

```
"=====  
Gram-Schmidt modificado ====="
```

```
"norm(Q*R - A)"
```

```
1.776D-15
```

```
"norm(Q^T*Q - I)"
```

```
5.514D-16
```

Nota-se que, para matrizes comuns, os algoritmos obtiveram desempenhos bem similares, não variando muito o erro numérico tanto da aproximação da  $QR$  para a  $A$  quanto da ortogonalidade da  $Q$ .

## Exercício 4

Agora, vamos escrever funções para calcular a decomposição  $QR$  de uma matriz com base no refletor de Householder. Primeiro, temos a versão normal do algoritmo escrita abaixo.

```
// Função da versão 1 do algoritmo de Householder para decomposição QR  
function [U, R] = qr_House_v1(A)
```

```

// Pegando as dimensões da A
[m, n] = size(A)
// Inicializando a matriz U
U = zeros(m, n)

// Para cada coluna...
for j = 1:n
    // Pega o vetor que queremos projetar sobre um eixo
    x = A(j:m, j)
    // Escolhe a melhor das duas projeções possíveis
    if x(1) > 0 then
        x(1) = x(1) + norm(x)
    else
        x(1) = x(1) - norm(x)
    end
    // Calcula u normalizando x
    u = x/norm(x)
    // Salva u na matriz U
    U(j:m, j) = u
    // Triangulariza a parte da matriz correspondente
    A(j:m, j:n) = A(j:m, j:n) - 2*u*(u' * A(j:m, j:n))
end
// A R é a parte triangular superior da A
R = triu(A)
endfunction

```

Em seguida, vamos escrever uma versão modificada desse algoritmo, na qual as iterações sobre as colunas de uma matriz  $m \times n$  acontecem apenas até  $m - 1$  colunas se  $m \leq n$ . A explicação para isso é esta: a cada iteração, o algoritmo seleciona a coluna seguinte e zera todos os valores abaixo da diagonal da matriz nessa coluna, ou seja, abaixo do elemento  $A(j, j)$  da coluna  $j$ . No entanto, caso a matriz seja quadrada ou possua mais colunas que linhas, na  $m$ -ésima iteração, esse elemento da diagonal será o último elemento daquela coluna, não havendo nada abaixo dele para ser zerado (para iterações seguintes, ele apenas não selecionará nada). Portanto, podemos simplesmente desconsiderar essas últimas iterações.

Feita a explicação, abaixo está a função dessa 2ª versão do algoritmo.

```

// Função da versão 2 do algoritmo de Householder para decomposição QR
function [U, R] = qr_House_v2(A)
    // Pegando as dimensões da A
    [m, n] = size(A)
    // Inicializando a matriz U
    k = min(m-1, n)
    U = zeros(m, k)

    // Para cada coluna...
    for j = 1:k
        // Pega o vetor que queremos projetar sobre um eixo

```

```

x = A(j:m, j)
// Escolhe a melhor das duas projeções possíveis
if x(1) > 0 then
    x(1) = x(1) + norm(x)
else
    x(1) = x(1) - norm(x)
end
// Calcula u normalizando x
u = x/norm(x)
// Salva u na matriz U
U(j:m, j) = u
// Triangulariza a parte da matriz correspondente
A(j:m, j:n) = A(j:m, j:n) - 2*u*(u' * A(j:m, j:n))
end
// A R é a parte triangular superior da A
R = triu(A)
endfunction

```

Por fim, vamos escrever uma função para construir a matriz  $Q$  dessa decomposição com base nos vetores presentes nas colunas da matriz  $U$  fornecida pelo algoritmo.

```

// Função para construir a matriz Q
function [Q] = constroi_Q_house(U)
    // Pegando as dimensões da U
    [m, n] = size(U)

    // Inicializando Q como a identidade
    Q = eye(m, m)

    // Para cada vetor em U...
    for j = 1:n
        // Pega a coluna da matriz
        uj = U(:, j)
        // Calcula a matriz de Householder
        Qj = eye(m, m) - 2*uj*uj'
        // Multiplica à direita da Q
        Q = Q * Qj
    end
endfunction

```

#### Item 4.1)

Vamos testar a precisão desse método em comparação com os anteriores.

```

// Calculando a U e a R do método de Householder
[U1HH1, R1HH1] = qr_House_v1(A1);
[U1HH2, R1HH2] = qr_House_v2(A1);

```

```
// Calculando a matriz Q de Householder
Q1HH1 = constroi_Q_house(U1HH1);
Q1HH2 = constroi_Q_house(U1HH2);

disp("===== Q*R - A =====")
disp("Gram-Schmidt", norm(Q1*R1 - A1))
disp("Gram-Schmidt modificado", norm(QM1*RM1 - A1))
disp("Householder 1", norm(Q1HH1*R1HH1 - A1))
disp("Householder 2", norm(Q1HH2*R1HH2 - A1))
disp("===== Q^T*Q - I =====")
disp("Gram-Schmidt", norm(Q1'*Q1 - eye(2, 2)))
disp("Gram-Schmidt modificado", norm(QM1'*QM1 - eye(2, 2)))
disp("Householder 1", norm(Q1HH1'*Q1HH1 - eye(3, 3)))
disp("Householder 2", norm(Q1HH2'*Q1HH2 - eye(3, 3)))
```

"===== Q\*R - A ====="

"Gram-Schmidt"

1.776D-15

"Gram-Schmidt modificado"

1.776D-15

"Householder 1"

1.111D-14

"Householder 2"

1.111D-14

"===== Q^T\*Q - I ====="

"Gram-Schmidt"

2.292D-16

"Gram-Schmidt modificado"

2.292D-16

"Householder 1"

1.882D-15

"Householder 2"



1.882D-15

```
[U2HH1, R2HH1] = qr_House_v1(A2);
[U2HH2, R2HH2] = qr_House_v2(A2);

Q2HH1 = constroi_Q_house(U2HH1);
Q2HH2 = constroi_Q_house(U2HH2);

disp("===== Q*R - A =====")
disp("Gram-Schmidt", norm(Q2*R2 - A2))
disp("Gram-Schmidt modificado", norm(QM2*RM2 - A2))
disp("Householder 1", norm(Q2HH1*R2HH1 - A2))
disp("Householder 2", norm(Q2HH2*R2HH2 - A2))
disp("===== Q^T*Q - I =====")
disp("Gram-Schmidt", norm(Q2'*Q2 - eye(3, 3)))
disp("Gram-Schmidt modificado", norm(QM2'*QM2 - eye(3, 3)))
disp("Householder 1", norm(Q2HH1'*Q2HH1 - eye(4, 4)))
disp("Householder 2", norm(Q2HH2'*Q2HH2 - eye(4, 4)))
```

"===== Q\*R - A ====="

"Gram-Schmidt"

1.891D-15

"Gram-Schmidt modificado"

1.891D-15

"Householder 1"

2.722D-14

"Householder 2"

2.722D-14

"===== Q^T\*Q - I ====="

"Gram-Schmidt"

2.562D-16

"Gram-Schmidt modificado"

2.562D-16

"Householder 1"

2.144D-15

"Householder 2"

2.144D-15

```
[U3HH1, R3HH1] = qr_House_v1(A3);
[U3HH2, R3HH2] = qr_House_v2(A3);

Q3HH1 = constroi_Q_house(U3HH1);
Q3HH2 = constroi_Q_house(U3HH2);

disp("===== Q*R - A =====")
disp("Gram-Schmidt", norm(Q3*R3 - A3))
disp("Gram-Schmidt modificado", norm(QM3*RM3 - A3))
disp("Householder 1", norm(Q3HH1*R3HH1 - A3))
disp("Householder 2", norm(Q3HH2*R3HH2 - A3))
disp("===== Q^T*Q - I =====")
disp("Gram-Schmidt", norm(Q3'*Q3 - eye(5, 5)))
disp("Gram-Schmidt modificado", norm(QM3'*QM3 - eye(5, 5)))
disp("Householder 1", norm(Q3HH1'*Q3HH1 - eye(5, 5)))
disp("Householder 2", norm(Q3HH2'*Q3HH2 - eye(5, 5)))
```

"===== Q\*R - A ====="

"Gram-Schmidt"

8.882D-16

"Gram-Schmidt modificado"

1.776D-15

"Householder 1"

1.308D-14

"Householder 2"

1.308D-14

"===== Q^T\*Q - I ====="

"Gram-Schmidt"

6.279D-16

"Gram-Schmidt modificado"

5.514D-16

"Householder 1"

1.404D-15

"Householder 2"

1.404D-15

Assim, observa-se que o método de decomposição  $QR$  de Householder tem uma precisão bem semelhante aos métodos de Gram-Schmidt.

## Item 4.2)

### 1. Matriz mágica 7x7

A seguir, testaremos nossas funções com algumas matrizes especiais, geralmente instáveis. Começaremos com uma matriz mágica 7x7, na qual as somas dos elementos de cada linha, coluna e diagonal é a mesma.

```
M1 = testmatrix('magi', 7)
```

```
M1 =  
30.  39.  48.  1.   10.  19.  28.  
38.  47.  7.   9.   18.  27.  29.  
46.  6.   8.   17.  26.  35.  37.  
5.   14.  16.  25.  34.  36.  45.  
13.  15.  24.  33.  42.  44.  4.  
21.  23.  32.  41.  43.  3.   12.  
22.  31.  40.  49.  2.   11.  20.
```

```
// Calculando a decomposição QR pelos métodos de Gram-Schmidt  
[QM1GS, RM1GS] = qr_GS(M1);  
[QM1GSM, RM1GSM] = qr_GSM(M1);  
  
// Calculando a decomposição QR pelo método de Householder  
[UM1HH, RM1HH] = qr_House_v2(M1);  
QM1HH = constroi_Q_house(UM1HH);  
  
// Calculando a decomposição QR com a função do Scilab  
[QM1Sci, RM1Sci] = qr(M1);  
  
disp("===== Q*R - A =====")  
disp("Gram-Schmidt", norm(QM1GS*RM1GS - M1))  
disp("Gram-Schmidt modificado", norm(QM1GSM*RM1GSM - M1))
```

```

disp("Householder", norm(QM1HH*RM1HH - M1))
disp("Scilab", norm(QM1Sci*RM1Sci - M1))
disp("===== Q^T*Q - I =====")
disp("Gram-Schmidt", norm(QM1GS'*QM1GS - eye(7, 7)))
disp("Gram-Schmidt modificado", norm(QM1GSM'*QM1GSM - eye(7, 7)))
disp("Householder", norm(QM1HH'*QM1HH - eye(7, 7)))
disp("Scilab", norm(QM1Sci'*QM1Sci - eye(7, 7)))

```

"===== Q\*R - A ====="

"Gram-Schmidt"

7.105D-15

"Gram-Schmidt modificado"

1.029D-14

"Householder"

5.506D-14

"Scilab"

9.110D-14

"===== Q^T\*Q - I ====="

"Gram-Schmidt"

1.574D-15

"Gram-Schmidt modificado"

1.017D-15

"Householder"

6.063D-16

"Scilab"

6.171D-16

Parece que todos os métodos obtiveram resultados bem precisos para ortogonalizar essa matriz mágica.

## 2. Matriz de Hilbert 7x7

Agora, vamos testar com a inversa de uma matriz de Hilbert, cuja definição é a seguinte para cada elemento  $(i, j)$ :

$$H_{i,j} = \frac{1}{i+j-1}$$

```
H = testmatrix('hilb', 7)
```

```
H =
 49.      -1176.      8820.      -29400.      48510.      -38808.      12012.
-1176.     37632.     -317520.     1128960.     -1940400.     1596672.     -504504.
 8820.     -317520.     2857680.     -10584000.     18711000.     -15717240.     5045040.
-29400.     1128960.     -10584000.     40320000.     -72765000.     62092800.     -20180160.
 48510.     -1940400.     18711000.     -72765000.     1.334D+08     -1.153D+08     37837800.
-38808.     1596672.     -15717240.     62092800.     -1.153D+08     1.006D+08     -33297264.
 12012.     -504504.     5045040.     -20180160.     37837800.     -33297264.     11099088.
```

```
// Calculando a decomposição QR pelos métodos de Gram-Schmidt
[QHGS, RHGS] = qr_GS(H);
[QHGSM, RHGSM] = qr_GSM(H);

// Calculando a decomposição QR pelo método de Householder
[UHHH, RHHH] = qr_House_v2(H);
QHHH = constroi_Q_house(UHHH);

// Calculando a decomposição QR com a função do Scilab
[QHSci, RHSci] = qr(H);

disp("===== Q*R - A =====")
disp("Gram-Schmidt", norm(QHGS*RHGS - H))
disp("Gram-Schmidt modificado", norm(QHGSM*RHGSM - H))
disp("Householder", norm(QHHH*RHHH - H))
disp("Scilab", norm(QHSci*RHSci - H))
disp("===== Q^T*Q - I =====")
disp("Gram-Schmidt", norm(QHGS'*QHGS - eye(7, 7)))
disp("Gram-Schmidt modificado", norm(QHGSM'*QHGS - eye(7, 7)))
disp("Householder", norm(QHHH'*QHHH - eye(7, 7)))
disp("Scilab", norm(QHSci'*QHSci - eye(7, 7)))
```

```
"===== Q*R - A ====="
```

```
"Gram-Schmidt"
```

```
0.
```

```
"Gram-Schmidt modificado"
```

```

8.975D-09

"Householder"

0.0000001

"Scilab"

3.688D-08

"===== Q^T*Q - I ====="

"Gram-Schmidt"

0.9852109

"Gram-Schmidt modificado"

1.933D-09

"Householder"

1.447D-15

"Scilab"

3.746D-16

```

Curiosamente, o método de Gram-Schmidt normal obteve precisão máxima no quesito da decomposição da matriz  $H$ , mas ficou com um erro muito grande na ortogonalidade da matriz  $Q$ . Isso provavelmente ocorre devido a sua abordagem direta e simples na decomposição da matriz e ao fato de ela não preservar exatamente a ortogonalidade entre as colunas de  $Q$ , especialmente em matrizes mal-condicionadas como essa.

Com relação ao método modificado, seus resultados ficaram com uma precisão razoável, melhor que a do método normal. Por ser uma melhoria, o algoritmo atualizado geralmente mantém a precisão da decomposição da matriz e visa melhorar a ortogonalidade de  $Q$ .

Olhando para o Householder, ele obteve o resultado inverso do Gram-Schmidt: sua precisão na decomposição da  $H$  não foi tão boa, mas a ortogonalidade da  $Q$  obtida ficou muito alta. Uma possível razão para isso é que esse método preserva a ortogonalidade exata entre as colunas de  $Q$ , mesmo com a decomposição não sendo tão precisa.

Por fim, a função do Scilab ficou com resultados bons nos dois quesitos.

### 3. Matriz mágica 6x6

Por fim, vamos testar com outra matriz mágica, mas agora 6x6.

```
M2 = testmatrix('magi', 6)
```

```
M2 =  
35.   1.   6.   26.   19.   24.  
3.   32.   7.   21.   23.   25.  
31.   9.   2.   22.   27.   20.  
8.   28.  33.   17.   10.   15.  
30.   5.  34.   12.   14.   16.  
4.   36.  29.   13.   18.   11.
```

```
// Calculando a decomposição QR pelos métodos de Gram-Schmidt
```

```
[QM2GS, RM2GS] = qr_GS(M2);
```

```
[QM2GSM, RM2GSM] = qr_GSM(M2);
```

```
// Calculando a decomposição QR pelo método de Householder
```

```
[UM2HH, RM2HH] = qr_House_v2(M2);
```

```
QM2HH = constroi_Q_house(UM2HH);
```

```
// Calculando a decomposição QR com a função do Scilab
```

```
[QM2Sci, RM2Sci] = qr(M2);
```

```
disp("===== Q*R - A =====")
```

```
disp("Gram-Schmidt", norm(QM2GS*RM2GS - M2))
```

```
disp("Gram-Schmidt modificado", norm(QM2GSM*RM2GSM - M2))
```

```
disp("Householder", norm(QM2HH*RM2HH - M2))
```

```
disp("Scilab", norm(QM2Sci*RM2Sci - M2))
```

```
disp("===== Q^T*Q - I =====")
```

```
disp("Gram-Schmidt", norm(QM2GS'*QM2GS - eye(6, 6)))
```

```
disp("Gram-Schmidt modificado", norm(QM2GSM'*QM2GSM - eye(6, 6)))
```

```
disp("Householder", norm(QM2HH'*QM2HH - eye(6, 6)))
```

```
disp("Scilab", norm(QM2Sci'*QM2Sci - eye(6, 6)))
```

```
"===== Q*R - A ====="
```

```
"Gram-Schmidt"
```

```
7.957D-15
```

```
"Gram-Schmidt modificado"
```

```
7.960D-15
```

```
"Householder"
```

```
1.750D-14
```

```
"Scilab"
```

4.101D-14

"===== Q<sup>T</sup>\*Q - I ====="

"Gram-Schmidt"

0.9965096

"Gram-Schmidt modificado"

0.9374063

"Householder"

1.166D-15

"Scilab"

6.629D-16

Diferentemente da matriz mágica 7x7 testada anteriormente, essa 6x6 trouxe alguns problemas para nossos algoritmos. Isso se deve à peculiar característica dessa classe de matrizes de que seus espécimes de ordem ímpar são bem-condicionados, enquanto que os de ordem par são mal-condicionados.

Todos os métodos obtiveram aproximações boas na decomposição da matriz em  $Q$  e  $R$ .

No entanto, o Gram-Schmidt não obteve sucesso na ortogonalidade da  $Q$ , com ambas as versões ficando com erros altos. Uma possível causa para isso é a falta de robustez do método de Gram-Schmidt para garantir a ortogonalidade exata entre as colunas de  $Q$  em comparação com os outros métodos, especialmente com matrizes mal-condicionadas, introduzindo erros numéricos que afetam essa ortogonalidade.

Por outro lado, tanto o método de Householder quanto o do Scilab conseguiram resultados muito bons nesse quesito.

## Exercício 5

Por último, vamos usar a decomposição  $QR$  para encontrar os autovalores de uma matriz simétrica. A função para isso está a seguir.

```
// Função para calcular os autovalores de uma matriz por meio da decomposição QR
function [S] = espectro(A, tol)
    // Inicializando os vetores atual e anterior distantes para garantir a
    ↪ entrada no loop
    S = [%inf]
    S0 = [0]

    // Enquanto o vetor não convergir...
    while norm(S - S0, 'inf') > tol
```



```

        // Salva o valor anterior
        S0 = S
        // Calcula a decomposição QR da matriz
        [Q, R] = qr_GSM(A)
        // Substitui ela por RQ
        A = R*Q
        // Pega a diagonal dessa matriz como os autovalores
        S = diag(A)
    end
endfunction

```

Vamos testar com algumas matrizes.

```

// Gerando uma matriz simétrica
A4 = 20 * rand(3, 3) - 10;
A4 = round((A4 + A4')/2)

// Vendo quais são seus autovalores
autovalores = spec(A4)

// Calculando esses autovalores com nossa função
S4 = espectro(A4, 10^(-8))

```

```

A4 =
    5.   -5.   -1.
   -5.    4.    2.
   -1.    2.   -4.
autovalores =
   -4.4768213
   -0.3632067
    9.8400280
S4 =
    9.8400280
   -4.4768213
   -0.3632067

```

```

A5 = 20 * rand(4, 4) - 10;
A5 = round((A5 + A5')/2)

autovalores = spec(A5)

S5 = espectro(A5, 10^(-7))

```

```

A5 =
  -10.   -2.   -7.   -1.
   -2.    4.    1.    1.
   -7.    1.   -7.   -3.
   -1.    1.   -3.   -5.

```

```

autovalores =
  -16.316859
  -5.5016052
  -0.9370026
  4.7554671
S5 =
  -16.316859
  -5.5016049
  4.7554669
  -0.9370026

```

```

A6 = 20 * rand(5, 5) - 10;
A6 = round((A6 + A6')/2)

autovalores = spec(A6)

S6 = espectro(A6, 10^(-6))

```

```

A6 =
  9.    1.    5.    2.    5.
  1.   -9.    1.    4.   -1.
  5.    1.    5.    4.   -1.
  2.    4.    4.   -7.   -3.
  5.   -1.   -1.   -3.   -6.
autovalores =
  -12.599706
  -9.3512946
  -4.0616507
  4.2589108
  13.753740
S6 =
  13.753740
  -12.599706
  -9.3512946
  4.2589013
  -4.0616413

```

Nossa função está funcionando perfeitamente!